

UAV と AI を活用した河川巡視時のペットボトル検出における画像生成 AI の適用に関する基礎的研究

岡山大学 学生会員 ○下江 大地

岡山大学 学生会員 潘 是均

岡山大学 正会員 吉田 圭介

岡山大学 正会員 西山 哲

株式会社東京建設コンサルタント 非会員 小島 崇

1. はじめに

近年、我が国では、河川において大量のごみが発見されており、「荒川クリーンエイドリ」による調査では、河川ごみのうち、ペットボトルが多く発見されている。ペットボトルは、自然環境中で、分解されにくく、様々な環境汚染を引き起こすため、河川において問題となる。そこで、現在、パトロールカーを用いた目視による河川巡視にて不法投棄ごみの発見・回収・処分が実施されている。最近では、河川巡視業務の高度化・効率化に向け、UAV 撮影画像及び、画像解析技術(AI)を活用した河川巡視²⁾に取り組まれている。しかし、画像解析技術を用いて高精度の検出を行うためには、様々な背景・対象物が映った空撮画像をより多く収集し、AIに学習させる必要がある³⁾。そして、大量の空撮画像の収集・処理には、多くの時間や労力が必要となる。そこで、画像解析技術において生成画像が学習データに適用可能であれば、効率よく、大量の画像が利用できる。

本研究では、河川ごみとしてペットボトルを対象とする。画像生成 AI「Stable Diffusion」を利用して、ペットボトルを含む画像生成を行い、学習データ(Train)と検証データ(Valid)に区分したデータセットを作成する。本研究では、「低高度 UAV 撮影画像」と「生成画像」をそれぞれ学習させ、「低高度 UAV 撮影画像」をテストデータに利用した時の検出精度の比較により、学習データ生成における画像生成 AI の適用の妥当性を検証する。

2. 使用した AI モデルの概要

2.1 Stable Diffusion

Stable Diffusion⁴⁾は、「入力したテキスト」をもとに画像を生成する「訓練済の AI モデル」を搭載した画像生成 AI である。本研究では、「Stable Diffusion」モデルに搭載された「Inpaint」機能を利用する。「Inpaint」は、

元画像をベースに、新たな画像を生成する手法である。

「Inpaint」の特徴は、変更したい部分をマスク化し、「入力したテキスト」をもとにマスク化した部分が変更され、新たな画像が生成できることである。そのため、対象物以外を変更せず、背景を固定して、画像生成できる。ここで、「Inpaint」での生成例を図-1 に示す。

2.2 YOLOv5

YOLOv5⁵⁾は物体検出の代表的なモデルである YOLO のバージョンの 1 つであり、画像の中に写った対象の物体の位置・種類を特定できる深層学習モデルである。YOLOv5 は処理が高速であり、リアルタイムでの実行も可能で、顔検知や自動運転などに応用されている。

3. 研究方法

3.1 低高度 UAV 撮影画像の特徴

本研究では、データセットに、オープンデータであり、低高度 UAV 撮影画像である UAV_BD⁶⁾を利用した。

Wang ら(2018)⁶⁾は、低高度 UAV 物体検出のための新しいデータセット(UAV_BD)を提案した。そして、ペットボトルの発見と位置特定を目指すとともに、小さくて透明な物体を検出できる物体検出モデルの開発が促進される。UAV_BD は、図-2 に示すように、8 つの背景(①Sand, ②Lawn, ③Bush, ④Land, ⑤Step, ⑥Mixture, ⑦Ground, ⑧Playground)に区分されており、方向バウンディングボックスを使用して、アノテーションがされている。



図-1 Inpaint での生成例

キーワード 河川巡視, UAV, ペットボトル, Stable Diffusion, YOLOv5, F 値

連絡先 〒700-8530 岡山市北区津島中 3-1-1 岡山大学大学院環境生命自然科学研究科

TEL086-251-1111




図-2 UAV_BD



図-3 生成画像 (AIGC_BD)

3.2 画像生成 AI の利用

本研究では、「Stable Diffusion」にある「Inpaint」機能を利用し、画像生成時には、生成のしやすさ及び、画像の質の観点からパラメータを設定した。

「Inpaint」機能により、元画像に UAV_BD を利用して生成した画像（以下、AIGC_BD と示す。）を図-3 に、示す。

3.3 データセットの作成

UAV_BD を背景ごとに Train, Valid, Test データに分けたデータセットとし、それぞれの画像枚数を表-1 に示す。本研究では、UAV_BD の背景 Mixture は、残りの 7 つの背景が混在したデータセットであるため、Mixture を省いた残りの背景 7 種類のデータセットを利用した。表-1 中の「Natural」は、自然的な背景 Sand, Lawn, Bush を、「Artificial」は、人工的な背景 Step, Ground, Playground を、「All」は、7 つの背景すべてをまとめたデータセットである。Land は、自然的、人工的な背景が混在しているデータセットである。

「Inpaint」により生成した「AIGC_BD」では、7 つの背景それぞれ 100 枚ずつ生成を行い、Data Augmentation を利用して画像枚数をさらに増加させ、Train, Valid データに分けた。Data Augmentation を利用した理由は、「Inpaint」手法では、物体の向き・位置が一定であるため、データの偏りが生じ、過学習の可能性があるからである。

学習データには、4 種類のデータセット(①UAV_BD, ②AIGC_BD, ③UAV_BD+AIGC_BD のデータセットをすべて混合させた「Full version」、④UAV_BD+AIGC_BD のデータセットをそれぞれ半分ずつ抽出し、混合した「Half version」)を利用し、それぞれの画像枚数を表-2 に示す。

表-1 UAV_BD の画像枚数

			Train/Valid	Test
			画像枚数	画像枚数
UAV_BD	Natural	Sand	827/207	258
		Lawn		
		Bush		
		Land		
	Artificial	Step		
		Ground		
		Playground		
	All		5789/1449	1806

表-2 学習データセットの画像枚数

		Train/Valid
		画像枚数
UAV_BD		5789/1449
AIGC_BD		5945/926
UAV_BD+	Full version	11734/2375
AIGC_BD	Half version	5871/1193




図-4 検討 Case

図-4 は、本研究での検討 Case を示す。

3.4 YOLO の設定

YOLO の学習時には、画像サイズ、epoch 数、batch サイズを設定する必要がある。YOLOv5 では、画像を正方形にリサイズして学習を行う。本研究では、画像サイズを 352 pixels とし、batch サイズを 50、epoch 数を 1000 とした。

また、YOLO の評価時には、confidence score と IoU の閾値を設定する必要がある。本研究では、confidence score を 0.001、IoU の閾値は変更せずデフォルトの 0.45 とした。

4. 解析結果

本研究では、精度評価に、誤検出の割合を示す「適合率」と未検出の割合を示す「再現率」の調和平均である「F 値」を利用した。「F 値」は、0~1 の範囲で表され、1 に近いほど精度が良いといえる。

表-3 は、図-4 で示した UAV_BD, AIGC_BD を利用した 4 つのデータセットを学習させた時のテストデータ(UAV_BD)における F 値を示す。表-3 をみると、AIGC_BD 学習時の方が、全体的に検出精度が低くなった。しかし、AIGC_BD 学習時では、他の学習データと比べて精度が低くなったものの、全背景「All」において検出精度が約 0.9 と高精度の結果が得られた。

図-5 は、AIGC_BD 学習時の検出例、図-6 は、UAV_BD

表-3 検出結果 (F 値)

Train		UAV_BD	AIGC_BD	UAV_BD+AIGC_BD 「Full version」	UAV_BD+AIGC_BD 「Half version」
Test	Sand	0.955	0.923	0.961	0.959
	Lawn	0.990	0.959	0.991	0.993
	Bush	0.977	0.926	0.980	0.977
	Land	0.977	0.844	0.951	0.953
	Step	0.980	0.925	0.985	0.979
	Ground	0.964	0.828	0.931	0.934
	Playground	0.987	0.886	0.979	0.970
	Natural	0.973	0.935	0.977	0.974
	Artificial	0.977	0.882	0.964	0.961
	All	0.975	0.895	0.967	0.965




図-5 AIGC_BD 学習時の検出結果




図-6 UAV_BD 学習時の検出結果

学習時の検出例を示す。図-5 と図-6 の検出結果を比較すると、どちらも高い検出自信度で認識ができています。また、7 種類のどの背景においても生成画像 AIGC_BD を学習させたときの方が現地の UAV_BD を学習させたときよりも高い検出自信度が得られました。そのため、学習データに生成画像を利用した場合でも、物体検出において、ペットボトルの特徴量を十分に捉えられるという結果となった。このことから、生成画像のみを学習させたモデルでも高精度な検出結果が得られたため、学習データに生成画像の適用が可能であるといえる。

また、「Full version」と「Half version」を比較すると、画像枚数に約 5,800 枚の違いがあったものの検出精度に大きな差は見られなかった。これは、特徴量が十分に捉えられていたため、画像枚数を増やしても、精度に大きな差が出なかったと考えられる。

5. まとめ

本研究では、学習データに画像生成 AI「Stable Diffusion」で生成した画像と UAV 撮影画像を利用した時の検出精度の比較を行うことにより、生成画像が学習データとして利用可能であるかを検討した。生成画

像 AIGC_BD を学習データに利用した場合、現実の撮影画像 UAV_BD よりも検出精度は劣るものの、全体の背景に対して、F 値が約 0.9 と高精度の検出結果が得られた。また、生成画像 AIGC_BD を学習させた場合で、検出自信度が最も高くなった。この結果から、生成画像が学習データとして利用可能であるといえる。

今後の課題として、本研究では、学習データとテストデータに同じ背景を有する画像を利用したため、学習データと異なる地点を検出する場合の精度の検討が必要である。また、河川巡視で利用される高高度 UAV 撮影画像を利用した際の精度も検討する必要がある。

謝辞

本研究は、岡山大学が DOWA ホールディングス株式会社と東邦電気産業株式会社の寄付により実施した事業の支援を受けました。関係各位に感謝の意を表します。

参考文献

- 1) 荒川下流河川事務所：荒川クリーンエイド，<https://www.ktr.mlit.go.jp/arage/arage00014.html>.
- 2) 井関禎之，船田征，西山哲：UAV 写真を用いた不法投棄物の把握，土木学会論文集，79 巻，22 号，2023.
- 3) 高橋悠太，藤井純一郎，天方匡純：Stable Diffusion を用いたドローン河川巡視用 AI のデータ増強と特徴量補完の可能性検証，AI・データサイエンス論文集，4 巻，3 号，2023.
- 4) <https://github.com/AUTOMATIC1111/stable-diffusion-webui>.
- 5) <https://github.com/ultralytics/yolov5>.
- 6) Wang, J., Guo, W., Pan, T., Yu, H., Duan, L., & Yang, W. (2018, July). Bottle detection in the wild using low-altitude unmanned aerial vehicles. In 2018 21st International Conference on Information Fusion (FUSION) (pp. 439-444). IEEE.