

水中カメラの画像と深層学習による 魚道を遡上する稚アユの検出に関する検討

潘 是均¹・古谷 峻¹・吉田 圭介²
山下 泰司³・小島 崇⁴・白神 義章⁵

¹ 学生会員 岡山大学大学院 環境生命科学研究科 (〒700-8530 岡山市北区津島中 3-1-1)

E-mail: p4b36znn@s.okayama-u.ac.jp (Corresponding Author)

² 正会員 岡山大学准教授 学術研究院環境生命科学学域 (同上)

³ 岡山県農林水産総合センター水産研究所研究員 (〒701-4303 瀬戸内市牛窓町鹿忍 6641-6)

⁴ 株式会社東京建設コンサルタント 環境防災研究所 (〒170-0004 東京都豊島区北大塚 1-15-6)

⁵ 株式会社ウエスコ 農村環境計画課 (〒700-0033 岡山県岡山市北区島田本町 2-5-35)

河川を遡上する稚アユの個体数の把握はアユの資源量調査において重要である。しかし、現在は水中カメラ画像を長時間かけて目視確認することにより計数を行っている。本研究では岡山県吉井川の鴨越堰の魚道出口に設置した水中カメラの画像を利用してデータセットを作成し、物体検出の深層学習アルゴリズムである YOLOv5 を用いることで、遡上する稚アユの検出モデルを作成した。モデルによる検出の結果、アユのデータ数の増加にともない精度が向上したが、アユと誤判定されやすい対象物へのラベリングでは、データ数が少数の場合は精度が低下した。本研究のモデルにより、目視計数をすべき画像枚数は従来の 1% 弱に抑えられ、また、モデルで画像を判別する場合、約 2 か月分の画像処理で、従来の手法より所要時間が約 90 時間短縮されると試算された。

Key Words: object detection, deep learning, juvenile Ayu, underwater camera, fishway

1. はじめに

アユは秋にふ化し、一般的に海へ下って成育した後、春に河川を遡上してから親アユとなり秋の産卵で一生を終える。1 年で全長 30 cm 程度まで成長するアユは夏の味覚として、また、釣りの対象種として人気があり、内水面漁業における重要な漁獲対象種である。一方、その漁獲量は全国的に減少しており¹⁾、カワウによる食害や冷水病によるへい死といった自然的要因に加え、漁業就労者の減少といった社会的要因が考えられ²⁾、稚魚放流をはじめとした資源の増大を図る対策が実施されている。アユの漁獲量を増大させるには、天然アユの資源増大が必要であり、その年の天然資源量の指標となる春の遡上量は資源回復に向けた対策を検討する上で重要なデータとなる³⁾。

従来のアユ遡上調査は堰堤など観察、計数しやすい地点を設定し、人が現地に常駐することで実施されてきた⁴⁾。ただし、アユの遡上は数週間に及び、信頼性の高い、連続的なデータを取得するには多大な労力を要する。このため、近年ではカメラを用いた画像確認による遡上量

調査が試行され⁵⁾、岡山県農林水産総合センター水産研究所でも県東部の一級河川である吉井川下流域の鴨越堰右岸魚道(図-1)において、水中カメラを用いた遡上調査が実施されている。ところが、稚アユを計数する画像確認に時間と労力を要するとともに、アユとその他の魚種を見分ける知識や経験が必要となり、当初の目的であった労力の軽減には至っていない。また、全国的に見ても画像を活用したアユの簡易な計数手法についての実用例は限られている。




図-1 吉井川と鴨越堰の場所
(Google 社「Google Earth」に加筆)




図-2 魚道の全体図と水中カメラの設置場所




図-3 魚道の出口から見た写真

近年、深層学習による物体検出のアルゴリズムの開発が進んでおり、代表的なものに本研究で使用したYOLOv5⁹⁾をはじめとするYOLOシリーズのほか、R-CNNやSSDなどが挙げられる。太田ら⁷⁾は河川を流れるマクロプラスチックを検出し、種類を判別する研究、野村ら⁸⁾はコンクリート表面のひび割れ検出システムの研究をYOLOにより行っており、深層学習による物体検出技術は今後のさらなる利用が期待される。また、長良川では魚道上部に設置したビデオカメラの映像から、深層学習モデルにより遡上アユを計数する試みがなされているが⁹⁾、魚道での工事が必要であり、費用がかかる上に迅速な設置ができないという問題点がある。

本研究では、水中カメラで撮影された遡上調査の画像をYOLOv5で深層学習し、安価かつ簡易的に魚道を遡上する稚アユの検出モデルを作成することで、計数に要する労力の軽減を目標とした。また、学習を行う教師データを大量に用意することが困難な場合に、事前解析でアユと誤判定されやすかったイシマキガイにラベリングをすることで精度の向上を図るとともに、教師データ数と検出精度を検証し、最低限必要となるデータセットを検討した。今後、他のフィールドにおける検出モデルの作成も想定しつつ、従来の目視確認とYOLOv5で深層学習させたモデルによる手法との作業効率を比較し、本手法の実用性について検討した。

2. 対象河川と従来の調査方法

(1) 対象河川および堰

吉井川は岡山県東部に位置し、児島湾の東端に注ぐ、幹川流路延長133km、流域面積2110km²の一級河川である(図-1)。岡山県水産研究所ではアユの資源量を把握

表-1 混同行列

		目視計数	
		アユである	アユではない
モデルの予測	アユである	TP (True Positive)	FP (False Positive)
	アユではない	FN (False Negative)	TN (True Negative)

するため、吉井川の河口から7.4kmに位置する鴨越堰において春にアユの遡上調査を行っている。この堰は吉井川の潮止堰で、下流側は汽水域となっている。海域である児島湾で育成したアユは春にこの堰を遡上することから、堰内への進入および遡上アユの観察が容易な右岸の魚道上部で調査が実施される(図-2)。

(2) 水中カメラを用いたアユ遡上調査方法

水産研究所のアユ遡上調査は、鴨越堰右岸魚道の出口にある2箇所の通水路のうち1箇所に、ステンレス製の防水ケースに入れたBrinno社製のタイムラプスカメラTLC200Proを設置して行った(図-3)。カメラに写る距離は濁度にもよるが、概ね通水路の半分ほどである。2021年は4月8日～6月9日の63日間において、1週間に1度程度の頻度で回収した画像をパーソナルコンピュータ(以下、PCとする)のモニターで再生し、アユを目視で計数した後、1日ごとの遡上尾数として集計した。撮影設定は、間隔を2秒、撮影時間帯を光量が確保される6:00～18:00とした。記録画像は画素数1,280pixels×720pixelsのAVI形式で保存され、PC上でAVI2JPG(フリーソフト)を用いて再生した。ここで確認する画像枚数は、1時間あたり1,800枚、1日あたり21,600枚となり、1日分の画像確認に要する時間は、撮影されたアユの数量によって労力が異なり15～120分となる。

3. アユ検出モデルの開発と検出の試行

(1) 物体検出とYOLOv5の概要

物体検出とは、画像内に含まれる人や車などの物体を取り囲む領域を特定することである。物体検出の精度の評価指標は式(1)～(3)のPrecision、Recall、F値を使用した。TP、FP、FNは表-1の混同行列により定義される。Precisionは検出モデルが正解であると判別したもののうち、実際に正解だったものの割合、Recallは実際に正解であったもののうち、検出モデルが正解と判別できたものの割合、F値はPrecisionとRecallの調和平均を示し、本研究ではモデルのアユに対するF値の向上を目指した。これらの値は0から1の値を取り、1に近づくほど良い検出結果である。

$$\text{Precision} = \frac{TP}{TP+FP} \quad (1)$$

表-2 学習用データセット（画像枚数とデータ数）

	Trainデータ	Validデータ
画像枚数(枚)	230	56
アユ(尾)	335	86
オイカワ(尾)	8	2
ボラ(尾)	5	1
モクズガニ(個体)	2	1
ヨシノボリ類(尾)	10	2
マゴイ(尾)	3	1



図-4 アユの尾鰭のみが写った画像の例

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (2)$$

$$F \text{ 値} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3)$$

本研究での深層学習のモデルには、2020年6月にGlenn Jocherにより発表されたYOLO (You Only Look Once)¹⁰⁾シリーズのYOLOv5(GNU General Public License v3.0)を使用した。本モデルを選択したのはインターネットから無料でダウンロードが可能であること、自作のデータセットを用いた学習が容易であるなどの理由による。さらに、YOLOv5の中で最も学習時間が短いYOLOv5sを選択した。

(2) データセットの作成

YOLOv5に学習させるためのデータセットの作成には、2021年4月18日～6月9日に撮影された画像のうち、代表的な魚介類が撮影された静止画286枚を用いた。なお、確認された魚介類は表-2に示したアユやボラなどの6種とイシマキガイであった。用意した静止画については、まず画像1枚ごとに魚介類の位置と種類を記述したtxt形式のファイルを作成するラベリングが必要となり、ここでは表-2に示した通りにラベリングを行い、このファイルと静止画像を加えてデータセットとした。なお、一連の作業はlabelGo-Yolov5AutoLabelling(MIT license)を用いて行った。作成したデータセットは、深層学習に供するためTrainデータとValidデータに分割した。分割の際には、まずアユが写っている画像をランダムに8:2となるように分割し、それぞれTrainデータとValidデータに入れた。その後、その他の種類は種類ごとに最低1尾(個

体)はValidデータに入るように分割し、それぞれをTrainデータとValidデータに入れた。また、表-2のデータセットのラベリングに約150分を要した。

(3) 深層学習の学習条件

深層学習ではTrainデータの画像をいくつかのセットに分割し、セットを1つ学習するたびにモデルのパラメータを更新する。全てのセットを一通り学習させた後、Validデータを推論させ、その時点でのモデルの性能評価を行う。Validデータの正解とモデルの推論結果の誤差をValidation Lossといい、深層学習ではその値を小さくするように学習を進める。Validation Lossを小さくするための最適化アルゴリズムは、現在広く使われているAdam (Adaptive Moment Estimation)を選択した¹¹⁾。また、Trainデータの総学習回数をepoch数といい、一般にValidation Lossはある学習回数で最小となったのち、増加する。YOLOv5は学習時にValidation Lossが最小の時のパラメータを保存しており、本研究ではepoch数が1000までにValidation Lossが最小になったため、epoch数は1000とした。

YOLOは画像を正方形に変更して学習することから、変更後の画像サイズの一边は水中カメラの画像の長辺と同じ1,280 pixelsとした。また、Trainデータを分割した各セットの枚数をバッチサイズといい、本研究では48枚とした。これらの設定はGPUのメモリを最大限使用できる数値となるよう留意した。計算環境は、NVIDIA社製のGPUである、Geforce RTX3090を使用し、メモリは24 GB、CUDAコア数は10,496であった。なお、学習に要した時間は約50分であった。

(4) 学習済みモデルでの稚アユの検出

水産研究所が目視計数した画像について、深層学習を行ったモデルによりアユの検出を行った。対象画像は目視によるアユ検出数が各1尾と少ない2021年5月9、12日およびアユが多数確認された5月13、14日の4日間分とし、YOLOv5の学習用に供した画像を除く、86,375枚をモデルの精度評価に使用するTestデータとした。この4日間には表-2に示したアユ以外の魚種はほとんどいなかった。ただし、目視による検出数には、頭部や尾鰭といった魚体の一部のみのアユや、カメラから離れた場所を遡上する不鮮明なアユなど、モデルでは検出が困難なものが含まれていた(図-4中の赤枠)。そのため、本試行で正解としたアユの検出数は、全身が鮮明に写っているアユのみの数値とした。なお、鴨越堰の画像には濁度が高い場合もあるが、本研究では濁度の上昇により画質が低下する場合は対象画像とはしていない。また、現場の特徴として、この堰にはイシマキガイが多く生息し藻類も繁茂するほか(図-4)、魚道出口の通水部は水深が浅く、幅が狭くなるため、水面の流れに乱れが生じ(図-3)、日射の強い日には川底に細長い影ができる。事前解析ではこれらがアユと誤判定されることがあった。




図-5 モデルにより正しくアユと検出できている例




図-6 モデルが影をアユと誤判定している例

(5) 検出精度の向上手法

表-2 に示したデータセットの学習済みモデルによる Test データ内の稚アユの検出を行ったのち、以下の 3 つの手法で稚アユ検出モデルの精度向上と必要なデータ数の検討を行った。検出されたアユの例を図-5 に示す。

a) イシマキガイへのラベリング

Train データ内のイシマキガイのデータ数増加によるアユの F 値の変化を見る。これにより、ターゲットの検出精度を上げるために、誤判定をするものをラベリングする際の基準を調べる。データ数を増加する際には、Train データ中の画像をランダムに選択し、その画像内のイシマキガイにラベリングした。Train データ、Valid データのイシマキガイ以外の種類のデータ数は全て表-2 から変更していない。また、Train データのイシマキガイにラベルが付いているときには、Valid データでは全てのイシマキガイにラベリングをした。

b) アユのデータ数の変更

Train データ内のアユの数を変更した際のアユの F 値の変化を見る。これにより、大規模なデータセットの作成が難しい場合に、どの程度のデータセットを作れば求める精度が出るのかを調べる。アユのデータ数を变化させたデータセットは、Train データのアユが写っている画像をランダムに選択した後、Train データのアユが写っていない画像と合わせて作成した。なお、Train データと Valid データのイシマキガイ全てにラベリングし、Valid データのイシマキガイへのラベリング以外は表-2 から変更していない。

表-3 各データセットの説明

データセット名称	イシマキガイへのラベリング	追加した背景画像の枚数 (追加した背景画像の割合)
データ(1)	全てにラベリング	0枚(0%)
データ(2)	なし	0枚(0%)
データ(3)	なし	14枚(5%)
データ(4)	なし	29枚(10%)
データ(5)	なし	43枚(15%)




図-7 ラベリングしたイシマキガイの割合とアユの F 値

c) 誤判定した背景画像のデータセットへの追加

イシマキガイ全てにラベリングをするのは非常に手間がかかる。YOLOv5 の作成者である Glenn Jocher は 0～10%程度の背景画像をデータセットに加えることを推奨している¹²⁾。背景画像とは判別対象が写っていない画像であり、背景画像をデータセットに加えるとは、対象画像に全くラベリングをせずにデータセットに加えることである。この目的はモデルがアユと誤判定したものをアユではないと学習させることである。そこで、表-2 に示したデータセット（イシマキガイへのラベリングなし）を深層学習した稚アユの検出モデルによって、影（図-6）や藻類、イシマキガイをアユと誤判定した画像を表-2 のデータセットに追加することで精度向上を図った。作成したデータセットを表-3 に示す。背景画像を追加する際は誤判定をした背景画像を 50 枚集め、必要な枚数だけランダムに抜き出し、抜き出した画像を 8:2 に分割して Train データと Valid データに追加した。

4. 稚アユの検出結果と精度向上手法の検討

(1) 作成した検出モデルによる稚アユの検出結果

表-2 に示したデータセットを深層学習した稚アユ検出モデルにより、Test データで検出をした際のアユに対する F 値は 0.708 であった。

(2) イシマキガイのデータ数の増加による精度変化

Train データ中のイシマキガイ全てにラベリングした場合を 100%（データ数：6,241）とし、その割合ごとのアユの検出の F 値を図-7 に示した。ラベリングをした割合が 0%の場合の F 値は 0.708 であったが、ラベリングの




図-8 アユのデータ数の変化にともなうアユのF値




図-9 誤判定をした背景画像を追加した場合の結果

割合が 20%~40%では F 値は 0.5~0.6 に低下し、80% (図-8 中の赤線) のラベリングで 0.741 と向上した。最終的に全てのイシマキガイにラベリングすると F 値は 0.795 となった。F 値は 50%未満のラベリングでは 0%の場合よりも低下しており、少ないデータ数ではイシマキガイの特徴量の学習には不十分であったと考えられた。本研究で課題となったイシマキガイのように検出対象以外のものによる誤判定を減らして精度の向上を図るには、80%以上のラベリングが必要と考えられた。

(3) アユのデータ数の変化による精度変化

Train データにおけるアユのデータ数を変化させたアユ検出の F 値を図-8 に示した。データ数が 70 尾では F 値は 0.358 であったが、データ数の増加とともに F 値は向上し、200 尾程度で 0.732 (図-9 中の赤線)、最高データ数 335 尾で 0.795 となった。200 尾~335 尾で一定程度の精度が得られることが示唆され、アユのデータ数を 200 尾まで増やしたときのアユの F 値の増加量に比べ、200 尾以降は F 値の増加量が少なかった。そのため、本研究のように教師データの量が限られる場合、検出対象のデータ数は 200 尾程度が目安になりうると考えられた。

(4) 誤判定した背景画像を追加した場合の精度変化

表-3 に示した 5 パターンのデータセットによる学習済みモデルの検出結果を図-9 に示した。誤判定のあった背景画像を追加したデータ(3), (4), (5)のうち、追加前のデータセット (データ(2)) と比べて F 値が上昇したのは、29 枚追加した割合 10%のデータ(4)のみであった。また、いずれのデータセットも最も精度の良いアユ検出




図-10 実務での利用方法

表-4 各作業の所要時間

検出モデルによる計数		従来の目視計数	
作業内容	所要時間	作業内容	所要時間
データセットのラベリング (イシマキガイのラベリングを含む)	17時間		
深層学習	50分		
1日分の画像の検出、計数	10分		
(参考) 10日分の所要時間		1日分の目視確認	2時間
19時間30分		20時間	

モデル (データ(1): 全てのイシマキガイにラベリング) の F 値 0.795 には及ばなかった。追加した背景画像数に比例して精度が向上しなかったのは、元々のデータセットが 286 枚であり、かつ追加した背景画像の枚数も限られていたこと、また、様々な時間帯や濁度の状況の背景画像を加えたため、精度向上に寄与した画像もあれば、適切な学習を妨げる画像もあったことが要因となった可能性がある。そのため、今後、追加する背景画像の割合だけではなく、精度向上に寄与する背景画像はどのようなものを明らかにする必要がある。

5. アユ検出モデルの実用性の検討

本研究では、最高で 0.795 の F 値を有するアユ検出モデルを開発することができたものの、誤判定の課題が残っている。目視による精度検証は依然として必要であり、それを加味した本モデルの利用方法を図-10 に示した。

水産研究所におけるアユの目視画像の枚数は、1 日につき 21,600 枚である。本検出モデルによりアユを含む画像を予め抽出すれば、確認枚数を削減することができる。例えば、本研究で用いた 4 日間分の Test データの約 86,400 枚について、F 値が最も高い検出モデルを活用し、モデルの設定である閾値を 0.7 から 0.5 にして Recall が 0.9 以上となるよう調整すると、モデルがアユを含むものとして出力した画像が 592 枚となった。ここでの Recall は 0.923 で、この 592 枚の画像を目視で計数すると稚アユの 92.3% が検出されることになる。本研究における各作業の所要時間 (表-4) から、検出モデルによる計数と目視計数とを比較したところ、トータルの所要時間は 10 日

分以上の計数で検出モデルが下回った。水産研究所の2021年の調査日数は63日間であり、この場合には約90時間の短縮となる。この調査は経年的に実施されることを踏まえると、所要時間は大きく短縮される。

6. 結論

本研究ではアユの資源量を把握するため、岡山県吉井川下流の鴨越堰の魚道出口に設置した水中カメラの画像を用いてデータセットを作成して深層学習を行い、遡上する稚アユの検出モデルを作成した。モデルでの稚アユの検出の結果、次の知見が得られた。

- 1) イシマキガイをアユと誤判定することを防ぐため Train データの 80% 以上、Valid データの全てのイシマキガイをラベリングすることによって精度が向上した。また、誤判定した背景画像をデータセットに加える手法では精度は向上したが、枚数に比例した精度向上は見られなかった。
- 2) アユのデータ数を 200 尾まで増やしたときのアユの F 値の増加量に比べ、200 尾以降は F 値の増加量が少なかった。深層学習のデータセットが十分に用意できない場合、アユのデータ数 200 尾程度が最低限準備すべきデータ数の目安となりうる。
- 3) 本研究で作成したモデルの使用法を検討したところ、人が確認する必要がある画像が従来の 0.7% に抑えられた。また、データセットの作成から検出まで行う場合には 10 日分以上の検出をすることで、従来の目視計数より所要時間が短縮された。

今後、2022 年の画像の活用、輝度やコントラストの変更といったデータ拡張の実施による精度向上について検討するほか、本研究で作成したモデルを活用し、リアルタイム計数の実施についても検討する予定である。労力を低減しつつ魚類の現況を正確に把握することで、河川

に住む生物の生態把握や河川工事、ダムの放流が河川環境に与える影響など、実務での利用も行いたい。

謝辞：本研究では公益財団法人 河川財団・河川基金による研究助成を受けた。記して謝意を表する。

参考文献

- 1) 農林水産省: 内水面漁業生産統計, 2021 年版.
- 2) 水産庁: 内水面漁業・養殖業をめぐる状況, 2021.
- 3) 高橋勇夫ら: 天然アユの本, pp.225-229, 築地書館, 2016.
- 4) 近藤正美ら: 吉井川流程の堰がアユの遡上に及ぼす影響と遡上状況, 岡山水研 HP, <https://www.pref.okayama.jp/uploaded/attach/206364.pdf>, 2014. (閲覧日: 2022 年 5 月 26 日)
- 5) 高瀬智洋: 簡易な間欠動画システムの開発とアユ遡上調査への利用, 東京都水産海洋研究, 第 6 号, pp.31-38, 2018.
- 6) Ultralytics: YOLOv5, <https://github.com/ultralytics/yolov5>, (閲覧日: 2022 年 5 月 26 日)
- 7) 太田ら: 深層学習に基づく河川マクロプラスチック面積算出・種類判別手法の開発, 土木学会論文集 B1(水工学), Vol.77, No.2, I_901-I_906, 2021.
- 8) 野村ら: 深層畳み込みニューラルネットワークに基づくコンクリート表面のひび割れ検出システム, 土木学会論文集 F6(安全問題), Vol.73, No.2, I_189-I_198, 2017.
- 9) 独立行政法人水資源機構長良川河口堰管理所: 長良川河口堰におけるアユ遡上数自動計数システムの構築: AI 画像認識を用いたアユ遡上数調査の効率化, ダム技術, 425, pp.91-96, 2022.
- 10) Joseph, R. *et al.*: You Only Look Once: Unified, Real-Time Object Detection, IEEE Conference on Computer Vision and Pattern Recognition, pp.779-788, 2016.
- 11) 岡谷貴之: 深層学習 改訂第 2 版, pp.47, 講談社, 2022.
- 12) Ultralytics, Glenn Jocher: YOLOv5 Tips for Best Training Results, <http://github.com/ultralytics/yolov5/wiki/Tips-for-Best-Training-Results>, (閲覧日: 2022 年 5 月 26 日)

(Received May 31, 2022)
(Accepted September 1, 2022)

A STUDY ON DETECTION OF FISHWAYS RUNNING-UP JUVENILE AYU USING UNDERWATER CAMERA IMAGES AND DEEP LEARNING

Shijun PAN, Ryo FURUTANI, Keisuke YOSHIDA
Yasushi YAMASHITA, Takashi KOJIMA and Yoshiaki SHIRAGA

Understanding the number of juvenile ayu running upstream is crucial for ayu stock assessment. However, counting is currently done by visual inspection of underwater camera images, which is a time-consuming task. In this study, we used images from underwater cameras installed in a fishway at Kamo-goshi weir on the Yoshii River in Okayama Prefecture to train a model for detecting juvenile ayu running upstream using YOLOv5 (i.e., a deep learning algorithm for object detection). The model's ayu detection results showed that accuracy improved as the amount of ayu data increased. When labeling an object that is easily misidentified as ayu (i.e., *Clithon retropictum*), accuracy decreased using small amount of data. Using our model, the number of images requiring visual counting was reduced to less than 1 % of the conventional visual confirmation. Furthermore, using our model in a two-month ayu stock survey is expected to reduce the required time by about 90 hours when compared to the conventional method.