

ノリ養殖漁場でのクロダイの食害把握に向けた 水中画像の深層学習と教師データ基準の検討

吉田 圭介¹・潘 是均²・横山 貴洋³・山下 泰司³
上田 勇輝²・杉野 博之³・小島 崇⁴

¹正会員 岡山大学学術研究院准教授 環境生命自然科学学域 (〒700-8530 岡山市北区津島中 3-1-1)

E-mail: yoshida.k@okayama-u.ac.jp

²学生会員 岡山大学大学院 環境生命科学研究科 (同上)

E-mail: prnn5b6s@s.okayama-u.ac.jp (Corresponding Author)

³岡山県農林水産総合センター水産研究所研究員 (〒701-4303 瀬戸内市牛窓町鹿忍 6641-6)

⁴株式会社東京建設コンサルタント 環境防災研究所 (〒170-0004 東京都豊島区北大塚 1-15-6)

近年の岡山県の養殖ノリ生産量減少の一因としてクロダイの食害があり、その蟄集状況の効率的な把握に向けて対象種を撮影した水中カメラ画像への深層学習モデルの適用が考えられる。モデルが学習する教師データの質は検出精度を左右するが、自然環境下では不鮮明な画像があり、客観的条件を設けてラベリングすることは困難であった。本研究では不鮮明に写った対象種に対して、近年開発された画像領域分割モデル SAM を活用し、ラベリングの対象基準を設けてクロダイ検出モデルを作成した。また、実海域での計数に際してモデルが検出し難い画像の特徴を分析し、教師データに追加すべき画像を検討した結果、SAM で検出可能なクロダイ画像と、それ以外の不鮮明なクロダイ画像の両方を教師データに含むと精度向上において効果的であることが示唆された。

Key Words: object detection, deep learning, *Acanthopagrus schlegelii*, nori seaweed farm, SAM

1. はじめに

我が国では各地でノリ養殖が営まれ、有明海、瀬戸内海を中心に 2020 年度には約 66 億枚が生産されている^{注1)}。岡山県の同年度の生産枚数は、全国 8 位となる 15 億枚で、漁業産出額の約 3 割を占めており本県の主要な漁業種類に位置付けられている^{注1)注2)}。ノリは秋から春にかけて養殖されるが、近年は秋季の水温降下の遅れによる生育不良や冬季の栄養不足による品質低下に加え、カモやクロダイによる食害が発生し、漁業者の高齢化に伴う廃業も相まって、本県の生産枚数はピーク時の 4 割程度にまで減少している^{注3)}。その中でもクロダイの食害は、収穫の始まる 12 月頃の生産不調の一因と考えられ、漁業者も被害の激化を危惧している。

岡山県農林水産総合センター水産研究所（以下、水産研究所）では、県内のノリ生育不良の原因を特定するとともに、効果的な防除網の設置手法など食害防止の対策に繋げるため、水中カメラによる撮影手法^{注4)}を用いてノリを喫食するクロダイの出現時間帯や場所ごとの違い、喫食方法を調査している（図-1）。近年、魚類を対象とした環境 DNA^{注5)}やバイオロギング^{注6)}といった調査法も普及する

中、本手法は食害状況の視覚的な確認や蟄集状況の数値化が可能なことに加え、漁業者に記録した画像を提示することで、本種に対する危機意識を高めるツールとなっている。一方、養殖現場のニーズに応じて調査点数が多くなるとカメラの設置や管理に要する労力が増大し、記録した画像確認に要する時間も多大となる。効率的にクロダイの出現状況を把握し、数値化する手法が求められており、近年利用が進んでいる深層学習による物体検出技術を適用するのに望ましい機会と言える。近年のニューラルネットワークを用いた画像に対する物体検出技術は発展が著しく、その技術は様々な分野で実用化されつつある。




図-1 養殖ノリの真下に群れるクロダイ




図-2 対象海域と撮影調査点

(a)対象海域 (b)児島湾口部 (c)笠岡島しょ部 (d)水島海域

本研究で対象とするような、水中画像における魚介類の物体検出は種々の開発事例が報告されており⁴⁾、岡山県においても河川の魚道を遡上するアユの検出研究がある⁵⁾。ただし、数日間に及ぶ自然環境下の撮影画像については、光量や濁度の変化に伴い記録される画像の質が様々な特徴を有し、目視では検出対象となる場合でも、深層学習モデルでは輪郭や魚体色が不鮮明で検出が困難となることがある。これらを解決するには、量および質を考慮した教師データの作成が重要となり、撮影画像における目的魚種のラベリング対象の基準が必要不可欠と考えられる。本研究で対象としたクロダイについても、撮影距離が遠く不鮮明なものに関して、本種を見慣れた水産関係の専門職員でもどこまでラベリングの対象とすべきか、客観的な情報として共有することは容易では無かった。

そこで本研究では、クロダイ検出モデルの高精度化に必要な教師データの作成のため、近年、膨大な量の教師データを基に開発された画像領域分割用途の深層学習モデル Segment Anything Model (SAM)^{注4)}を活用してラベリング対象の基準を設定し、特徴が不鮮明な教師データの選択的な作成と、その教師データを学習した検出モデルの有用性について検討した。また、ノリ養殖漁場に出現する本種の計数における実務での利用に向けて、輪郭や魚体色が鮮明なクロダイを高い精度で検出するモデルの作成を目標としつつ、教師データの構成を工夫することで不鮮明な個体の検出精度について検討した。

2. 対象海域と調査方法

(1) 対象海域と調査地点

岡山県の海域は東西 75km の細長い海域で、ノリ養殖は吉井川および旭川が流入する児島湾口部、高梁川が流入する水島海域、笠岡島しょ部の海域で営まれている。本研究では各海域の図-2に示したノリ養殖漁場の4地点において、水中カメラによるクロダイの撮影調査を実施した。




図-3 水中カメラを水面上から撮影した状況

表-1 対象海域の撮影調査地点と撮影期間

撮影調査地点	撮影期間	撮影時間
笠岡	2020年11月25日～28日	6:15~17:30
水島	2022年12月2日～6日	6:00~18:00
	2022年12月9日～12日	
下水島	2020年12月7日～14日	5:00~19:30
長洲	2022年12月1日～7日	6:00~17:00

(2) 水中カメラを用いたノリ養殖漁場でのクロダイ撮影

クロダイの撮影調査では、ノリ網を展開する養殖施設の外枠のロープに、ステンレス製の防水ケースに入れた Brinno 社製のタイムラプスカメラ TLC200Pro を設置した。養殖ノリを摂食するクロダイの姿を確認するため、ノリ網の直下が撮影範囲に入るよう、カメラの位置や画角を可能な範囲で調整した(図-3)。なお、視認可能な奥行は約 1~2m までであった。各対象海域における撮影期間と撮影時間の諸元を表-1に示す。海域ごと、また日時により、撮影調査点の海水の透視度やカメラの画角は微妙に異なる。そのため、撮影された画像は撮影調査点ごとの魚類の写り方に特徴が見られた。撮影間隔は2秒間とし、撮影された静止画像は 1,280pixels×720pixels の AVI 形式の動画ファイルとして保存される。

(3) 目視による計数作業

目視による計数は、魚種判別の経験や知識を有する水産研究所職員(以下、専門職員)の複数名が動画ファイルをパソコン上で再生して行った。計数時には、クロダイの魚体の輪郭が明瞭で体色を判別できる個体を「鮮明に写ったクロダイ」とし、そうでなくとも、魚体の向きや鰭などの部位からクロダイと判断できる個体を「不鮮明に写ったクロダイ」と区別した。なお、各専門職員間で判別結果が異なる個体は、3名相互で結果を補正し、最終的な計数値とした。

3. 深層学習モデルによるクロダイの検出の試行

(1) 物体検出モデル YOLOv5 の概要と精度評価の方法

物体検出とは、画像内の物体の位置とその種類、大き

表-2 混同行列

		目視確認	
		クロダイである	クロダイでない
モデルの予測	クロダイである	TP (True Positive)	FP (False Positive)
	クロダイでない	FN (False Negative)	TN (True Negative)

$$\text{Precision(P)} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad \text{Recall(R)} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad \text{F値} = \frac{2 \times \text{P} \times \text{R}}{\text{P} + \text{R}}$$

表-3 データセット 1-A の撮影地点毎の画像内訳

撮影地点	Train		Valid		Test	
	枚数	ラベル	枚数	ラベル	枚数	ラベル
笠岡	160	282	20	34	27	35
水島	56	133	6	20	13	8
下水島	160	340	20	42	27	43
長洲	208	269	27	34	34	31

さを推定する画像解析手法である。本研究では検出モデルとして、深層学習モデルである YOLOv5^{注9}を用いた。YOLOv5 はインターネット上にコードが公開されており、導入が容易で、学習時の計算処理や検出が比較的高速で行うことができる。YOLOv5 には、n, s, m, l, x の順に大きくなるレイヤーサイズなどが異なるモデルが複数あり、このサイズが大きくなれば検出精度が向上するが、それと同時に学習・推論に要する時間や、機器の必要メモリ数も増加する。本研究では精度とコストのバランスを勘案して YOLOv5s を用いた。

検出モデルの精度評価には、物体検出問題では一般的な Precision, Recall および F 値 (表-2) を使用した。モデルの予測が実際にラベリングされたクロダイであれば、TP に相当し、ラベリングがついていても、モデルが予測できなければ FN に相当する。Precision は、モデルがクロダイであると判断したもののうち、実際にクロダイであった割合である。Recall は、実際はクロダイであったもののうち、モデルがクロダイと判別できた割合である。F 値は Precision と Recall の調和平均である。

(2) データセットとクロダイ検出モデルの作成

YOLOv5s でクロダイを検出するモデルを作成するにあたって、対象海域で撮影された画像 (表-1 のデータソース) のうち、クロダイが写っている画像を無作為に抽出した。

YOLOv5s での学習及び精度評価では、撮影された画像と、その画像に写っている物体の種類と各物体の位置、大きさを記録 (ラベリング) した txt ファイルをセットとしたデータを用意する必要がある。本研究では上記で無作為に抽出した画像に対して、専門職員がデータセットを作成した (表-3, データセット 1-A)。また、このデータセット (枚) を教師データ (Train データ: 約 80%, Valid データ: 約 10%) と評価データ (Test データ: 約 10%) にランダムに分割した。Valid データは学習時に、Test データは精度評価時に利用した。なお、Test データ作成時にはクロダイの写っていない画像を含めて、クロダイ以外の異

物を誤検出しないかどうかを調べた。データセット 1-A の教師データを学習したモデルを「モデル 1-A」とした。

(3) 深層学習モデルの学習環境

本研究では深層学習モデルの学習と推論 (検出) では全て、GPU (NVIDIA GeForce RTX3090) を用いた。GPU のメモリは 24GB, CUDA コア数は 10,496 であった。学習時には画像サイズ, epoch 数, batch サイズの各パラメータを定める必要がある。画像サイズは、YOLOv5 では画像を正方形にリサイズして学習を行う際の一边の pixel 数を指定できる。本研究では画像サイズは 1280 pixels とした。また、batch サイズは、画像サイズとの兼ね合いになるが、GPU のメモリを最大限利用できる値に定めた。epoch 数は Train データの学習回数を指すが、本研究では 500 とした。これらのパラメータ設定で、学習に要した時間は約 200 分であった。

(4) モデル 1-A の検出結果

モデル 1-A について、データセット 1-A の Test データの推論を行い検出精度を評価した結果、クロダイに対する Precision, Recall, F 値はそれぞれ、0.962, 0.862, 0.909 であり、いずれも高い値となった。データセット 1-A の Test データの推論結果を確認したところ、大半のクロダイを見落とすことなく検出していたが、水中の気泡や浮き (ブイ) をクロダイと誤検出する例が見られた。

(5) 教師データの追加処理

上記の誤検出を改善するため、以下に示す 2 通りの教師データの追加を検討した。

a) Data Augmentation によるデータ拡張

実海域では気象や波浪状況などの要因から、撮影画像の輝度は異なる場合があるため、教師データには存在しない現地の状況変化に対応できるモデルが望ましい。そこで、ここでは YOLOv5 の Data Augmentation 機能の一部 (Random Brightness Contrast) を利用し、元画像に対して擬似的に輝度とコントラストを変更した画像の学習を行って、モデルの性能向上を検討した。変更は全画像に対して 50% の確率で行うものとした。輝度、コントラストの変化の範囲は元画像の -20% ~ 20% (デフォルト値) とした。

b) クロダイ以外の物体を含む背景画像の学習

YOLOv5 ではラベル無しの画像を学習させることで、クロダイがいないことを当該モデルに学習させることができる。そこで、クロダイが写っておらず、気泡やブイなど異物が含まれる画像 (背景画像) をデータセット 1-A の教師データに追加した。追加する枚数は、YOLOv5 制作者の推奨^{注9}を参照して学習用データセットの 10% の枚数とした。こうして作成されたデータセットを「データセット 1-B」、これを学習したモデルを「モデル 1-B」とした。なお、データセット 1-B の Test データはデータセット 1-A と同じとした。



図-4 気泡をクロダイと誤検出した例（上：モデル 1-A）と、背景学習で改善した例（下：モデル 1-B、同一画像）



図-6 輪郭が不鮮明に写ったクロダイ（黄色点線部）

(6) モデル 1-B の検出結果

モデル 1-A で推論を行った場合に、浮きや気泡などの異物をクロダイと誤検出することがあったが、モデル 1-B での推論ではそれらの誤検出の状況は改善された（図-4）。また、Data Augmentation の適用でクロダイの検出が可能となった例があった。その結果、背景画像学習とデータ拡張により、F 値は 0.909（モデル 1-A）から 0.944（モデル 1-B）へと精度が向上した（図-5）。モデル 1-B の誤検出の例を確認したところ、クロダイの輪郭が不鮮明な場合や、体色や鰭の特徴が見えづらい傾向があった（図-6）。

そこで、以下では次の 2 点を検討することとした。1 点目は専門職員が計数対象とするような、輪郭が不鮮明で、特徴が明瞭でないクロダイの画像を YOLOv5 が適切に学習し、また検出可能かどうかである。これに関しては本研究で扱う画像（クロダイの写り方）に限定し、定性的な扱いとはなるが、地点毎のクロダイ画像の不鮮明さの要因と、検出へ与える影響を分析することとした（4 章）。

2 点目は、そうした画像を YOLOv5 が学習可能であれば、可能な限り、効率的なラベル化が可能かどうかである。





図-5 Data Augmentation の適用でクロダイの検出が可能となった例（上：適用前、下：適用後）

これに関しては、目視による個々人での検出対象の判断は専門職員でも曖昧さは避けられず、また深層学習モデルにとって必要な多様性ある教師データ（特に、特徴は不明瞭だが、専門職員が検出対象とするクロダイ）を効率的に撮影画像から抽出するのは困難と考えられる。そこで、本研究では魚類を含む膨大かつ多様な、実画像の教師データに基づいて任意画像の領域分割を行う深層学習モデル（SAM、後述）を利用して、本研究で扱う画像の領域分割とクロダイのラベリングを行い、検出精度向上に寄与する教師データの抽出とデータ構成方法を検討した（5 章）。

4. 特徴が不明瞭な個体の出現状況の分析

データセット 1-B の 4 地点のうち、3 地点の画像を学習し、残りの 1 地点の画像を検出することで、地点毎の画像の特徴（不鮮明さ）の差異を確認することとした。表-4 は検出結果の精度を示すが、F 値はモデル 1-B よりも下がっており、特に、水島地点を検出対象とする場合に精度悪化が大きい。この要因として、教師データ量の減少が考えられるが、他に次の 2 点(a),(b)が指摘できる。

(a)長洲、笠岡、下水島地点が検出対象地点のときは F 値が近い値となった。しかし、水島地点が検出対象地点であるときは、他の 3 地点に比べ Recall 値と F 値が下がった。つまり、水島地点には他の 3 地点では確認されない、不鮮明な写り方のクロダイの画像があるものと考えられる。

(b)他地点とは異なり、水島地点は水質が比較的良かった。また、検出結果から、水島地点で検出が困難であったクロダイの写り方の特徴は、カメラから離れた位置で、輪

表4 試行パターン名と試行結果

試行名	学習地点	検出地点	Precision	Recall	F 値
I	笠岡, 水島, 下水島	長洲	0.897	0.632	0.742
II	長洲, 水島, 下水島	笠岡	0.848	0.635	0.726
III	長洲, 笠岡, 下水島	水島	0.919	0.511	0.657
IV	長洲, 笠岡, 水島	下水島	0.772	0.705	0.737




図7 撮影されたクロダイ（左）と、SAMを用いた領域分割の結果（右）

郭は不鮮明であるものの、体色の濃淡は分かり、体側のヒレなどの部位が確認できるものであった。一方、長洲・笠岡の地点では水島地点とは異なり、海水に濁りを有していた。下水島地点は濁りはないものの、日射の影響でシルエットのように写っていた。以上の分析を踏まえ、以下では水島地点での検出精度向上を目標に、データソースから効率的に検出困難な画像をいかに抽出し、またデータセット構成を工夫することで検出性能がどのように向上するのかを検討することとした。

5. Segment Anything Model を用いた画像認識と YOLOv5 モデルの教師データ作成への利用

(1) Segment Anything Model の概要

Segment Anything Model（以下、SAM）は、2023年4月5日に Meta（旧称 Facebook 社）から発表された、画像の領域分割を行う深層学習モデルである。Meta では本モデルを作成するにあたって、1100 万枚の画像と、それに付随する 10 億枚以上のマスクからなる膨大な教師データで学習を行っており、物体認識や領域分割の性能が高いことが期待できる⁹⁾。

(2) SAM を用いたラベル付け、モデル構成と検出精度

データセット 1-A（表-3）で対象とした画像に対して、SAM を用いて画像の領域分割を行った。図-7 は結果の一例を示す。ここで、左図の 2 つの黄色枠（2 尾のクロダイ）はデータセット 1-A でのラベル結果を示し、また右図は同一画像に対する SAM の領域分割結果であり、赤枠は左図の左側の 1 尾のクロダイに対応する。右側の 1 尾は SAM では認識されていない。本研究ではデータセット 1-A（表-3）で扱った画像に対して、SAM で捉えられた領域で、専門職員がクロダイと認識したラベルを新たにデータセット 2-A（表-5）とし、これを教師データとして学習したモデルをモデル 2-A とする。表-3 と表-5 のラベル数を比較すると、SAM は専門職員が検出対象とするよりも多くの

表5 データセット 2-A の撮影地点毎の画像内訳

撮影地点	Train		Valid	
	枚数	ラベル	枚数	ラベル
笠岡	160	334	20	37
水島	56	124	6	16
下水島	160	462	20	56
長洲	208	301	27	35

表6 精度検証での各深層学習モデルの教師データの設定

モデル名	モデルに用いた教師データの設定
モデル 2A	データセット 2A：表-3 に示した画像に対して SAM で捉えられたクロダイラベルのみ抽出
モデル 2B	データセット 2B：データセット 2A に対して、テストデータ*と日付・場所のどちらか異なるクロダイラベルを追加（表-7 参照）
モデル 2C	データセット 2C：データセット 2A に対して、テストデータ*と日付・場所が共に同じ画像内のクロダイラベルを追加（但し、テストデータは除く）

*2022 年 12 月 3 日に水島地点で取得した「水島計数対象データ」

クロダイを検出しているが、この特徴を調べた結果、データセット 2-A 内のクロダイは、4. で指摘した不鮮明な画像のうち、「魚体色が不明瞭で、黒いシルエットのように写る」クロダイが比較的多く、このタイプは専門職員が検出対象とすべきか判断に迷う場合が多いことがわかった。

また、モデル 2-A を用いてデータセット 1-A のテストデータを検出した際の検出精度は、Precision : 0.832, Recall : 0.858, F 値 : 0.845 であった。同一テストデータに対するモデル 1-A では、F 値が 0.944 であったため、モデル 2-A の検出精度が低下している。この理由は、上記の通り、モデル 1-A とモデル 2-A の教師データ内の不鮮明な画像の質の相違が関係しており、データセット 1-A のテストデータの不鮮明な画像（輪郭は不鮮明であるものの、体色の濃淡は分かり、体側のヒレなどの部位が確認できるもの）は、モデル 1-A では学習しているが、モデル 2-A では学習が十分に出来ていないものと考えられる。

(3) 目視計数結果による深層学習モデルの精度検証

対象海域で撮影された画像の計数作業の自動化の試みとして、深層学習モデルを用いたクロダイの検出と計数を行い、水産研究所の目視計数結果を正解として検出精度を調べることにした。

計数を行う対象画像は、2022 年 12 月 3 日に水島地点で撮影された映像のうちクロダイが写っているものを抽出




図-8 水産研究所での専門職員による目視計数とクロダイ検出モデルの各ケースごとの計数結果（2022年12月3日，水島地点）

した78枚である。以下このデータを「水島計数対象データ」と呼び、テストデータとする。このデータに対して、水産研究所の専門職員が1時間ごとの目視計数を行い、集計した。計数値は延べ数とし、複数の画像に写っている同一個体と思しきクロダイは別個体として扱った。

深層学習モデルによる検出では、教師データの影響を検討するため、表-6に示すモデルケース（条件）を設定した。ここで、モデル2-Bとモデル2-Cでは共に、モデル2-Aを基準として、SAMで認識しにくい不鮮明な特徴を持つと想定されるクロダイ画像を新たに学習した効果を検討するが、データセット2-Cはデータセット2-Aに加えて、水島地点であり、かつテストデータと同じ12月3日のデータを追加した。一方、データセット2-Bは、データセット2-Cの条件以外（水島地点で12月3日以外の場合、水島地点以外で12月3日の場合、および、水島以外で12月3日以外の場合、表-7参照）のデータを追加した。

図-8には目視計数結果と、クロダイ検出モデルの計数結果を示した。図中、黒色は目視計数結果であり、紫色はその中で「鮮明に写った」クロダイのみの検出数を示す。モデル2-Aの結果は紫色の結果を上回っており、SAM単独でも「鮮明に写った」クロダイ画像は概ね検出可能と考えられる。さらに、モデル2-B、2-Cの結果は2-Aの結果より良く、テストデータである「水島計数対象データ」に存在する「不鮮明さ（データセット2-C）」を含む画像が教師データに含まれると、精度が向上することが分かる。一方、表-8には図-8に示した各モデルの結果について、検出精度を示した。F値はRecall値の高低と連動し、また図-8のモデルの検出数は、検出数がある程度存在すれば、F値と同じ傾向を示している。

なお、検討ケースには設定していないが、「水島計数対象データ」のテストデータにラベルを付け、それらをすべて学習させたモデルを用いた検出では、専門職員と同じ計数結果となり、YOLOv5モデルは水島地点の123のデータ内の不鮮明さを有するクロダイ画像の検出が可能であった。検出モデルの作成では不鮮明なクロダイの画像をいかに効率的に教師データとして与えるかが重要だが、本研究の知見を整理すると、SAMで自動的に検出で

表-7 モデル2-B作成時に追加した教師データ（表-6参照）

データの諸元（地点、日付）	Train（枚）	Valid（枚）
水島,2022年12月5日	4	0
長洲,2022年12月3日	2	0
笠岡,2020年12月1日	15	2
下水島,2020年12月10日	8	1
下水島,2020年12月11日	66	8

表-8 各モデルの検出精度

モデル名	Precision	Recall	F値
モデル2-A	0.928	0.657	0.769
モデル2-B	0.929	0.672	0.779
モデル2-C	0.928	0.759	0.835

きるクロダイの不鮮明な画像をベースとして、SAMでは検出できない不鮮明さの特徴（輪郭やシルエットなど）を有するクロダイの画像を専門職員が優先的に抽出して教師データに加えることで、検出精度の向上が可能となるものと考えられる。

6. 結論

本研究ではノリ養殖漁場における食害状況の把握に向けて、岡山県の海域において水中カメラで撮影された画像と深層学習モデル YOLOv5s を用いてクロダイ検出モデルを作成した。検出精度向上のためにクロダイの特徴量が不明瞭な状況を分析すると共に、教師データの質を確保するために、特徴が不鮮明なクロダイ画像を同一基準で抽出する方法を検討した。さらに、深層学習モデルでの検出結果を専門職員による目視計数と比較し、精度向上に寄与するデータセットの構成を考察した。以下に得られた知見を示す。

(1) 教師データの基準を設けず、クロダイに見慣れた専門職員がラベリングしたクロダイ画像を学習した場合、ランダムに選ばれたテストデータに対して YOLOv5s による検出精度は F 値で 0.909(モデル 1-A)であり、背景画像やデータ拡張を適用すると 0.944(モデル 1-B)へと改善した。

(2) 画像領域分割モデル SAM を用いて認識でき、かつ専門職員によってクロダイと判断され、ラベリングされた画像を学習した場合、同テストデータに対して YOLOv5s による検出精度は F 値で 0.845 (モデル 2-A) であった。SAM が認識したものは「魚体色が不明瞭で、黒いシルエットのように写る」クロダイが比較的多く、このタイプは専門職員が検出対象とすべきか判断に迷うものが多いことがわかった。

(3) 実海域のクロダイ画像の不鮮明さは、被写体のカメラからの距離、水質や日射条件によって変化するが、専門職員が計数対象とするクロダイに限定すると、YOLOv5s の検出にとっては「輪郭の不鮮明さ」と「体色の不鮮明さ」に分類されるものと考えられる。

(4) YOLOv5s を用いた実海域のクロダイ画像の計数精度を向上させるには、専門職員が対象海域でのクロダイ画像の特徴を確認した後、SAM の検出結果を基準として、SAM で検出できるクロダイ画像と、検出できないクロダイ画像をそれぞれ教師データとして YOLOv5s に学習させると効果的である。

なお、本研究の成果は、限られた海域及び画像条件での検討と考えられるため、今後、多様な条件下での適用性を検討していきたい。

NOTES

注1) 農林水産省:海面漁業生産統計調査,2020年版。

注2) 農林水産省:漁業産出額,2020年版。

注3) 岡山県:岡山県水産振興プラン,2022

注4) Segment Anything Research by Meta AI, <https://segment-anything.com/>

注5) Ultralytics:YOLOv5,<https://github.com/ultralytics/yolov5/tree/v6.0>

REFERENCES

1) 手塚尚明, 梶原直人, 小栗一将, 喜安宏能, 渡部祐

志, 塩田浩二: 撮影手法を用いたノリ・アオノリ養殖場における食害種の出現記録, 日本水産学会誌, Vol. 89, No.1, pp.34-48, 2023. [Tezuka, N. et al.: The Recording of occurrences of herbivorous grazing species in a nori and ao-nori seaweed farming site by various camera methods, *Nippon Suisan Gakkaishi*, Vol.89, No.1, pp.34-48, 2023.]

2) 源利文, 山本哲史, 笠井亮秀, 近藤倫生: 環境 DNA を用いた沿岸域における魚類モニタリング, 沿岸海洋研究, Vol.53, No.2, pp.173-178, 2016. [Minamoto, T. et al.: Coastal Fish Monitoring Using Environmental DNA, *Bulletin on Coastal Oceanography*, Vol.53, No.2, pp.173-178, 2016.]

3) 宮下和士: バイオロギングによる海洋生物のモニタリング, 沿岸海洋研究, Vol.53, No.2, pp.169-172, 2016. [Miyashita, K.: Monitoring of Aquatic Living Resources Using Bio-logging Method, *Bulletin on Coastal Oceanography*, Vol.53, No.2, pp.167-172, 2016.]

4) 山本貴史, 玉置哲也, 岡崎慎一郎, 岡崎百合子, 吉田秀典, 末永慶寛: AI を用いた人工漁礁内における岩礁性魚類の資源生産力向上に関する研究, 土木学会論文集 B3(海洋開発), Vol.77, No.2, I_709-I_714, 2021. [Yamamoto, T. et al.: Research on the Improving Resource Productivity of Rock Fish in the Artificial Reefs Using AI, *Journal of Japan Society of Civil Engineers. Ser. B3*, Vol.77, No.2, I_709-I_714, 2021.]

5) 潘是均, 古谷峻, 吉田圭介, 山下泰司, 小島崇, 白神義章: 水中カメラの画像と深層学習による魚道を遡上する稚アユの検出に関する検討, 土木学会論文集 B1(水工学), Vol.78, No.2, I_127-I_132, 2022. [Pan, S. et al.: A Study on Detection of Fishways Running-up Juvenile Ayu Using Underwater Camera Images and Deep Learning, *Journal of Japan Society of Civil Engineers. Ser. B1*, Vol.78, No.2, I_127-I_132, 2022.]

6) Kirillov, A. et al : Segment Anything, <https://arxiv.org/abs/2304.02643v1>

(Received May 31, 2023)

(Accepted September 12, 2023)

DEEP LEARNING OF UNDERWATER IMAGES AND TRAINING DATA CRITERIA FOR UNDERSTANDING FEEDING INJURY OF *ACANTHOPAGRUS SCHLEGELII* IN NORI SEAWEED FARMS

Keisuke YOSHIDA, Shijun PAN, Takahiro YOKOYAMA, Yasushi YAMASHITA, Yuki UEDA, Hiroyuki SUGINO and Takashi KOJIMA

The decreasing production of cultured nori seaweed in Okayama Prefecture has been partly attributed to the feeding damage of *Acanthopagrus schlegelii*. We applied a deep learning-based detection model (YOLOv5) to underwater camera images of the target species to understand their feeding behaviors efficiently. It is commonly noticed that both the quality and quantity of training data greatly affects the detection accuracy of the model. However, it was challenging to establish objective conditions for labeling because some images were taken unclearly in the natural environment. In this study, we used the Segment Anything Model (SAM), which was recently developed to segment image regions based on huge amount of training dataset, to create a labeling criteria efficiently for unclear images. We analyzed the characteristics of images that were difficult for the SAM model to detect when counting the target species in actual sea areas. We also considered which unclear images should be selectively added to the training data based on the judge from fisheries professionals. Results showed that including both SAM-detectable and non-detectable unclear images of the target species in the training data would be effective in improving accuracy.