

土木学会論文集特集号（水工学） / Journal of JSCE Special issue (Hydraulic Engineering)

UAV写真と大規模マルチモーダルモデルを用いた河川投棄物検出手法の高度化に関する研究

--Manuscript Draft--

受付番号:	JSCE-JHE-D-25-00117R4
論文種別:	原著論文(和文)
標題:	UAV写真と大規模マルチモーダルモデルを用いた河川投棄物検出手法の高度化に関する研究
標題 (英語) :	STUDY ON AN ENHANCED METHOD FOR RIPARIAN WASTE DETECTION USING DRONE IMAGES AND A LARGE-SCALE MULTIMODAL MODEL
筆頭著者:	英 佑成
全著者:	英 佑成 吉田 圭介 潘 是均 小島 崇 西山 哲
全著者 (英語) :	Hanabusa Yusei Yoshida Keisuke Pan Shijun Kojima Takashi Nishiyama Satoshi
責任著者:	英 佑成 岡山大学 岡山市北区, 岡山県 JAPAN
抄録:	近年、河川管理の高度化は急務であり、UAVなどのプラットフォームとAIを活用した河川情報の取得が精力的に検討されている。本研究では、UAV航空写真、物体検出モデルYOLO及び大規模マルチモーダルモデルLLaVAを用いて、河川投棄物の検出と分類を行った。また、学習データには生成AIのStable Diffusionとweb上の公開UAV画像を用い、学習方法や推論画像の撮影高度が推論結果に与える影響を調べた。その結果、撮影高度が低く、生成AI画像のみを用いた場合、最も高精度に検出ができた。また、YOLOでの検出画像に対してLLaVAで投棄物を分類した結果、実寸法が比較的大きい発泡スチロール等には高精度に分類ができたが、高い高度での撮影画像や小さな物体では分類精度が低下する傾向が確認された。
分野:	50.200: 維持管理技術 _ Maintenance technology
キーワード:	Object Detection; YOLO; LLaVA; Stable Diffusion; UAV
追加投稿情報:	
質問	回答
6-3.講演者は、第一著者かつ今年度末（来年3月末日）32歳以下ですか？	Yes
Answer the following two questions.	
-Is the presenter the first author?	

-Is the presenter 32 years old or younger at the end of next March?	
生年月日を入力してください (例:1999/1/1) 6-3.講演者は，第一著者かつ今年度末 (来年3月末日) 32歳以下ですか？ Answer the following two questions. -Is the presenter the first author? -Is the presenter 32 years old or younger at the end of next March?に関連する質問	2002/05/15
6-1.水工学講演会の講演者の氏名を入力してください . 【注意事項】同一講演会でのご講演は一人一講演のみとなります . 違反された場合は関連論文の投稿を取り下げる場合がありますので複数の論文で講演者とならないようにご注意ください . Enter the name of the presenter.	英佑成

UAV 写真と大規模マルチモーダルモデルを用いた河川投棄物検出手法の高度化に関する研究

英 佑成¹・吉田 圭介²・潘 是均³・小島 崇⁴・西山 哲⁵

¹ 学生会員 岡山大学大学院 環境生命自然科学研究科 (〒700-8530 岡山市北区津島中 3-1-1)

E-mail: p1a30d8z@s.okayama-u.ac.jp (Corresponding Author)

² 正会員 岡山大学准教授 学術研究院環境生命自然科学学域 (〒700-8530 岡山市北区津島中 3-1-1)

³ Shen Zhen Institute for Advanced Study, UESTC (〒518110 Shenzhen City, Guangdong Province, China)

⁴ 株式会社東京建設コンサルタント 環境防災研究所 (〒170-0004 東京都豊島区北大塚 1-15-6)

⁵ 正会員 岡山大学教授 学術研究院環境生命自然科学学域 (〒700-8530 岡山市北区津島中 3-1-1)

近年、河川管理の高度化は急務であり、UAV などのプラットフォームと AI を活用した河川情報の取得が精力的に検討されている。本研究では、UAV 航空写真、物体検出モデル YOLO 及び大規模マルチモーダルモデル LLaVA を用いて、河川投棄物の検出と分類を行った。また、学習データには生成 AI の Stable Diffusion と web 上の公開 UAV 画像を用い、学習方法や推論画像の撮影高度が推論結果に与える影響を調べた。その結果、撮影高度が低く、生成 AI 画像のみを用いた場合、最も高精度に検出ができた。また、YOLO での検出画像に対して LLaVA で投棄物を分類した結果、実寸法が比較的大きい発泡スチロール等には高精度に分類ができたが、高い高度での撮影画像や小さな物体では分類精度が低下する傾向が確認された。

Key Words: Object Detection, YOLO, LLaVA, Stable Diffusion, UAV

1. はじめに

近年、ペットボトルや段ボールをはじめとする河川投棄物（以下、河川ゴミ）の増加が、深刻な環境問題として国内外を問わず注目されている。河川ゴミは生態系への影響や治水機能の低下だけでなく、景観の悪化といった問題を引き起こしている。日本各地で河川ゴミが確認されており、国土交通省や自治体による監視・対応体制の整備が進められている。

これに関連して、近年では UAV(Unmanned Aerial Vehicle)や航空機など様々な platform に搭載された各種のセンサーと人工知能 AI を用いた河川情報の取得が精力的に検討されている。例えば、河川ごみ点検を含め、UAV を用いた河川巡視においては、従来の人手による作業に起因する課題（作業の安全性向上、長区間河道での作業の効率化、作業ミスなど）が解決されるものと期待されている。

しかし、深層学習を用いた従前の研究、例えば UAV 写真から不法投棄物を検出するタスクでは、(1) 事前に解析者が設定した（または、限定的なデータを用いて学習した）対象物の特徴を有した物体しか検出されず¹⁾、また、(2) 廃棄された白いビニール袋と、日射で白く照らされた巨石が同じクラス分類として扱われる²⁾、といった問題が生じることがあり、人間のように柔軟かつ総

合的な判断（画角や日射条件等を考慮する柔軟性や、多数の現地経験に基づく判断）ができない。

一方、最近、人間が指示した特徴を有する音声、画像、動画などのメディア情報を大量に生成する「生成 AI」が一般に知られており、例えば Stable Diffusion^{注1)}を代表とする拡散モデルは画像生成において注目を集めている。水工学分野では例えば、下江ら³⁾は Stable Diffusion の Inpaint 機能を用いて、河川敷のペットボトル画像を数百枚程度、生成して学習させた物体検出モデルは、現実の画像を学習した場合と同程度の精度で対象物を検出できることを示した。ただし、検出対象がペットボトルのみであり、対象物が複数種類ある実際の現場とかけ離れており、複数種類の場合には大量の教師データの作成・アノテーション（投棄物の種類名称）が求められ、この作業は多大な労力を要するという課題が残された。

また、近年では自然言語を扱う大規模言語モデルと、音声や画像などの複数の情報の特徴を言語化して統合処理できる大規模マルチモーダルモデル（Large Multimodal Models, LMM）と呼ばれる人工知能が開発され、GPT-4 や Gemini といったアプリが一般に使われ始めている。LMM を用いて意図的に配置した“不法投棄物”を検出する取り組み⁴⁾もあるが、一般には投棄物の設置状況が比較的単純であるため、複雑な現実の地被状況下において、現在、開発途上にある各種 LMM がど

の程度、実用に供するかは不明である。

さて、現実の河川投棄物の検出では、対象物（その状態を含む）や地被の多様性が課題になる。実際に YOLO で対象物の分離・推論を行うとすると、一つの対象物につき数百から数千の学習データが必要となり多大な労力を伴う。そこで、本研究は(A)検出タスクと(B)分類タスクに分離する方法を試みた。

具体的には、前者(A)では河川敷での投棄物を対象として Stable Diffusion で作成した大量の画像を物体検出モデル YOLO (You Only Look Once) ^{注2)}に学習させて検出タスクのみを行い、後者(B)では検出された物体が何に相当するか、LMM の一種である Large Language-and-Vision Assistant (LLaVA) ^{注3)}に対して、事前に準備した選択肢の中から判断させることとした。また、本研究では実河川において投棄物を模擬した物体を散布して UAV 撮影を行い、(1)撮影時の画像解像度と、(2)学習する教師データの相違（生成または現実のデータ）が投棄物の検出や分類の精度に及ぼす影響を調べている。本研究の新規性は、上記のように異なる手段を組み合わせることで段階的に投棄物を検出・分類する試みだけではなく、従来の研究とは異なり、教師及び推論画像は全く別の場所や方法で得たデータセットであり、1つのデータセットの分割利用は行っていない。

2. 深層学習 AI モデルの概要と適用プロセス

(1) 画像生成 AI (Stable Diffusion)

本研究では教師データの作成に Stable Diffusion v1.5 を用いた。Stable Diffusion では利用者は主に2通りの方法で画像生成が可能である。一つ目は、目標とする特徴を持った画像を新規に生成する手法であり、自然言語のプロンプトから対応する画像を生成する「txt-to-image generation : txt2img」に分類される⁵⁾。二つ目は、利用者目標に近い特徴（構図、等）を持つ画像を入力し、そこにテキスト指示で適宜、修正を施しながら新たな画像を生成する「image-to-image generation : img2img」手法である。本研究では前者の方法で目標画像を生成し、物体検出 AI の学習データとして利用した。

(2) 物体検出モデル (YOLOv5)

物体検出とは、画像内の物体の位置とその種類、大きさを推定する画像解析手法である。本研究では検出モデルとして、下江ら³⁾が使用していた深層学習モデルである YOLOv5 を用いた。本モデルはインターネット上にコードが公開されており、導入が容易で、学習や検出が比較的高速で行うことができる。本研究では、COCO (Common Objects in Context) データセットで事前学習された YOLOv5 の高精度モデル (yolov5-l.pt) を使用し、アノテーション付きの画像データを用いて再学習を行った。また、このモデルを用いて UAV 空撮

画像に対して推論を行い、河川投棄物の検出性能を評価した。

(3) マルチモーダルモデル (LLaVA)

本研究では LLaVA-1.5-13B を用いた。LLaVA-1.5 は CLIP ベースの画像エンコーダと、13B パラメータの大規模言語モデル (Vicuna) を統合した構成を持ち、画像に対する質問応答や説明生成などのタスクに高い性能を示す。推論時に画像のみを入力すると、画像を説明するテキスト出力が得られる。また、画像と共にテキスト文 (Prompt) の入力を行うと、指示内容に沿ったテキスト出力が得られる。様々なベンチマークテストで他の LMM よりも高いスコアを出している点、オープンソースのため無償で利用できる点や、ローカル環境で実行することで解析の効率を向上できる点から本研究では LLaVA を選定した。

(4) 本研究の工程

本研究のプロセスは、3つのステップからなり、この概要を図-3 に示す。

a) 教師データ作成

2通りの方法を用いて教師データを作成した。1つは Stable Diffusion の txt2img 機能を用いて、著者らが擬似的な河川投棄物の画像データ（以下、AIGC (AI Generated content) と呼ぶ）を生成したデータである。もう1つは、UAV を用いて現実空間で低高度から撮影された投棄物または物体の写真であり、Internet 上で公開されたデータ（以下、UAVVaste ^{注4)}と呼ぶ）である。これらは共に、次の工程で利用するため、画像内の投棄物を囲むように長方形 (Bounding Box) を付けたデータセットとした。

b) 検出モデルによる推論

YOLOv5 を用いて a) のデータセットを学習した。その後、著者らがこのデータセットとは別に、現地河川で撮影した擬似的な投棄物の写真を対象に推論を行った。ここで、本研究では検出時のラベルは、投棄物の種類毎（例えば、段ボール、ペットボトル等）ではなく、全てまとめて「Waste」とした。これは自然物と人工物の特徴を区分する意味合いがある。

c) マルチモーダルモデルによる推論

b) で検出された Bounding Box 内の小画像に対して、LLaVA を用いて投棄物の種類を分類した。

3. 研究データ、解析条件および実行環境

(1) 教師データの生成条件と YOLOv5 での学習条件

Stable Diffusion (txt2img) を用いて作成する AIGC データの生成条件を表-1 に示した。図-4 には作成された AIGC の例を示す。AIGC は Prompt に “Riparian area” と指定しているため、背景には裸地や草地とい




図-3 本研究と既往研究³⁾のプロセス概要と相違

表-1 AIGC (Stable Diffusion, txt2img)での
画像生成時の条件設定

項目	入力値または内容
Prompt	Bikes, Cardboards, PET, Plastic Bags, High resolution, 8k camera, Bird view, UAV view, Riparian area
Sampling step	150
Width/Height(pix)	608/608, 900/600
Batch Size/Count	1/100
CFG Scale	7



図-4 AIGCの画像の一例



図-5 UAVVasteの画像の一例

表-2 UAVVasteのデータ仕様

項目	値または内容
画像枚数	772
ラベル数	3716
投棄物の種類	プラスチック容器、空き缶、ビン、ビニール袋、段ボール等（発泡スチロールは含まれない）

表-3 各データセットのラベル数

	training	validation
AIGC	6228	808
UAVVaste	6007	769

注) “training”は学習データそのもので、“validation”は学習時の「過学習」の状況を確認するための検証データ

表-4 各検討ケースでのYOLOv5の学習条件

Case	学習方法
1	AIGC のみ 6228 ラベル学習
2	UAVVaste のみ 6007 ラベル学習
3	AIGC の 6228 ラベル学習後に、続けて UAVVaste の 6007 ラベルを学習（転移学習）
4	UAVVaste の 6007 ラベル学習後に、続けて AIGC の 6228 ラベルを学習（転移学習）
5	AIGC の 6228 ラベルと UAVVaste の 6007 ラベルを同時に学習

った河川敷（“自然地形”）を有する画像が多い。画像の特徴としては、対象物の形状が明瞭であり、背景が単純である。また、表-2 に UAVVaste データセットの仕様を示す。図-5 に示す通り、UAVVaste も AIGC と同様に、自然地形の画像が多かった。こちらは、対象物が影や解像度不足により不明瞭であるこ

表-5 UAV撮影時の諸条件

撮影方法	移動撮影	
撮影アングル	垂直撮影	
使用機材	MAVIC 2 Pro	
飛行速度 (m/s)	30m	2.5
	60m	5.1
	100m	8.4
ISO	オート	
画像処理	Agisoft Metashape Professional に てオルソ画像に編集	

とや、背景が自然かつ不均一となっている。なお、本研究では Roboflow^{注5)}を用いて回転させることで、UAVVaste データに対してデータ拡張を行った。表-3 には本研究で用いた両データセットのラベル数を示す。AIGC のラベル数は UAVVaste と概ね同程度になるようにランダムに抽出した。

表-4 には本研究で検討した各ケースでの YOLO モデル学習時の教師データの組合せを示す。Case1 と Case2 は AIGC と UAVVaste を単独で学習したケース、また Case3 と Case4 は両者を交互に順に学習したケース、さらに Case5 は両者を混在させて同時に学習した条件である。YOLOv5 での学習時のバッチサイズは 16、画像サイズは 1024pixels とした。学習時はエポック数を 1000 に設定し、その他のパラメータはデフォルト値のままとした。

(2) 推論データと、YOLOv5 及び LLaVA の推論条件

本研究の推論データ（AI モデルの検証データ）を得るため、令和 7 年 4 月 8 日の晴天時に、岡山市内を南北に流れる一級河川・旭川 15km 左岸の河川敷において UAV を用いて写真を撮影した。UAV 撮影時の諸条件は表-5 に示す通りである。（地上解像度は各々、0.75cm/pix, 1.5cm/pix, 2.5cm/pix）と設定したが、後の検討で 100m 撮影写真での空き缶やペットボトルの検出や分類は比較的困難であったため、研究対象から除いた。

撮影背景として 2 箇所を設定し、1 つは草本や裸地で覆われた高水敷部（“自然地形”，図-6），またもう 1 つはコンクリートや道路、階段などが存在する高水敷から堤防法面周辺の箇所（“人工物”，図-7）とした。これら 2 か所には 5 種類の投棄物に見立てた日用品（河川での一般的な不法投棄物と考えられる、空き缶、ペットボトル、茶色の段ボール、白い発泡スチロール、透明と黄色のビニール袋。以下では“投棄物”と呼ぶ。なお、黄色のビニール袋は岡山市指定の有料ゴミ袋である）を人為的に設置し、“正解”の情報として内容と位置を記録した。撮影後は航空写真からオルソ画像を作成し、推論用データとした。検討に用いた画像サイズを表-6 に示す。




図-6 投棄物の設置箇所が裸地や草地である“自然地形”の場合の推論画像（撮影高度: 30m）




図-7 廃棄物の設置箇所がコンクリート等の“人工物”である場合の推論画像（撮影高度: 30m）

表-6 推論データの画像サイズ

撮影高度	撮影背景	画像サイズ(pixels)
30m	自然地形	3535×3123
	人工物	4824×3728
60m	自然地形	1833×1674
	人工物	2556×1700

YOLO による推論（検出）では Confidence は 0.1 に設定し、誤検出の増加をある程度、認めつつも、見逃しを低減させるようにした。また、LLaVA による分類時に用いた Prompt は以下の通り英文で入力し、選択肢から可能性の高いものを選ばせる方式とした。

“The background is a floodplain. What is shown in this image? Please select the most likely option from the choices below. Answer only with a number. 1. Plastic bottle, 2. Cardboard, 3. Can, 4. Plastic bag, 5. Styrofoam board, 6. Other”

この意図として、背景が河川敷であることを明記した上で、現地に配置した投棄物 5 種類に加えて、前段の検出時の誤り(Other)を抽出する目的がある。

(3) 実行環境と、推論結果の評価方法

YOLO と LLaVA の学習や推論では、GPU (NVIDIA RTX 6000 Ada Generation, メモリ: 48GB) を使用した。本研究での YOLO の用途は投棄物の検出であり、分類や誤検出は LLaVA で対応した。なお、LLaVA 実行時の、GPU メモリの使用量は 29GB 程度であった。そのため、YOLO の検出結果に対する精度評価の指標には再現率を、LLaVA のそれには正解率を採用した。なお、後述の結果から、ビニール袋は色の違いによって検出精度に有意な差が見られたため、透明と黄色のビニール袋を別々のクラスとして評価した。

4. YOLO による河川投棄物の検出結果

(1) 学習方法の違いによる影響

図-8 には YOLO での検出結果の一例を示す。これは撮影高度 60m の検出結果の一部を拡大したものである。画像内で黄色の物体はビニール袋だが、Case2, 3, 5 では検出可能であり、黄色の物体（ペットボトルなど）を含む UAVVaste を学習させたことが理由として推察される。しかし、UAVVaste を学習させた Case4 では検出できていない。これは、転移学習の際は 2 回目の学習データ (AIGC) に沿うように学習されるため、Case4 では AIGC で検出できなかった対象物への検出精度が低下したものと考えられる。

表-7 は撮影高度 60m 推論画像における各 Case での再現率を示し、地被背景毎と、それらの合計で併示した。合計の再現率では、画像生成された AIGC のみの Case1 が最も高く、UAVVaste のみの Case2 が最も低い。また、両データを学習した Case5 の結果は、その中間的な結果となっている。本研究では学習・推論データは全く異なる場所や方法で作成されたが、ある程度、投棄物の検出は可能と理解できる。一方、Case3 や Case4 は転移学習の結果だが、Case2 と同じ程度か、それ以下となっている。これは、AIGC では対象物の形状が明瞭で背景が単純な一方で、UAVVaste では影や解像度不足によって不明瞭かつ背景が自然かつ不均一であり異なっていたため精度向上に寄与できなかったものと考えられる。

(2) 撮影箇所の違いによる影響

表-7 において、撮影箇所の相違がもたらす効果を確認すると、自然地形に比べて人工物では再現率が減少しており、その減少値は Case に依らず約 10% から 15% 程度である。これは教師データと推論データでの背景地被の偏りによるものと考えられる。YOLO は物体と背景のコンテキストを一体のものとして学習する。教師データでは自然地形が相対的に多く、その場合、主に緑色や茶色の草本や裸地が含まれるが、一方、推論データに人工物が含まれる場合は、背景は主にアスファルトやコンクリ



図-8 YOLO 検出結果（図-6 の四角部の拡大図、右下の数字は Case 番号、赤色矩形は Bounding Box）

表-7 撮影高度 60m 推論画像での再現率(%)

Case	地被背景		
	自然地形	人工物	合計
1	61.0	44.7	52.5
2	45.5	35.3	40.1
3	44.2	36.5	40.1
4	46.8	35.3	40.7
5	51.9	41.2	46.3

表-8 撮影高度 30m 推論画像での再現率(%)

Case	地被背景		
	自然地形	人工物	合計
1	79.2	60.0	69.1
2	75.3	55.3	64.8
3	76.6	54.1	64.8
4	72.7	55.3	63.6
5	77.9	62.4	69.8

ートなどの灰色が主な色となり、学習データとコントラストや明度が異なったため検出精度が悪化したものと推察される。また、次節で説明する結果（表-8）より、背景の影響は撮影高度に依存しないことがわかる。

(3) 撮影高度の違いによる影響

表-7 と表-8 を比較すると、再現率は撮影高度によって大きく影響を受けることがわかる。高度が低い（地上解像度が高い）場合、どの Case においても再現率は向上しており、その値は 15% 程度から 25% 程度向上している。この理由として、(a) 解像度が高い場合には、投棄物の特徴が明確になりやすいこと、(b) 教師データが比較的、低い高度で撮影された状況が多いこと、(c) YOLO モデルは教師データを学習する際には、画像サイズを適宜、様々なパターンで変更しているが、教師画像の解像度が高い方が推論画像の特徴をより捉えられやすいためと考えられる。

表-9 撮影高度 30m 推論画像に対する、背景地被が自然地形での LLaVA による推論結果（百分率，混同行列）

		推論結果（LLaVA）					
		ペットボトル	段ボール	空き缶	ビニール袋	発泡スチロール	その他
正解	ペットボトル	39.1 (6.3)	8.7 (0.0)	0.0 (6.3)	4.3 (0.0)	4.3 (6.3)	43.5 (81.3)
	段ボール	0.0 (0.0)	100.0 (80.0)	0.0 (0.0)	0.0 (0.0)	0.0 (20.0)	0.0 (0.0)
	空き缶	15.4 (0.0)	0.0 (0.0)	0.0 (0.0)	7.7 (0.0)	0.0 (0.0)	76.9 (100.0)
	ビニール袋	0.0 (7.7)	0.0 (0.0)	0.0 (0.0)	92.9 (53.8)	0.0 (0.0)	7.1 (38.5)
	発泡スチロール	0.0 (0.0)	14.3 (0.0)	0.0 (0.0)	0.0 (0.0)	85.7 (100.0)	0.0 (0.0)
	その他	0.0 (0.0)	7.1 (4.8)	0.0 (0.0)	0.0 (0.0)	0.0 (4.8)	92.9 (90.5)

注) 括弧内の数字は、撮影高度 60m 推論画像の場合の結果である。小数点第 2 位を四捨五入した。




図-9 YOLO の Bounding Box 内画像（撮影高度: 30m）に対する LLaVA で推論結果例（説明文は左から、画像の画素数，正解ラベル名，推論結果を示す）

本章の(1)-(3)の結果を総合すると、生成 AI のデータ(Case1, AIGC のみ)は、解析者が指定した投棄物や背景地被の多様な特徴と、多様な解像度の画像を有することなどから、対象画像内の投棄物の検出精度が最も高くなったと推察される。

5. LLaVA による河川投棄物の分類結果

ここでは前章において最も再現率の高かった Case1 の検出結果を用いて、LLaVA による投棄物の分類を行った。表-9 は撮影高度 30m 推論画像に対して LLaVA を適用した場合の各投棄物の分類結果（混同行列，括弧内の数値は撮影高度 60m の場合の結果）を示す。表中の対角成分は、正しく分類された結果の割合（正解率）を

示すが、ここから段ボールやビニール袋、発泡スチロールなど、実寸法が比較的大きい投棄物は正解率が 85%以上であると確認できる。一方、ペットボトルや空き缶などの小さい投棄物は正解率が低く、空き缶では正解率が 0%であり、LLaVA がその他と誤分類している割合が高い。空き缶はサイズが小さいため、視認性が低く輪郭が捉えられなかったため背景と認識し、その他に誤分類したと考えられる。しかし、図-9(e)で示すような黒い色の空き缶では背景と空き缶の色の違いが鮮明に表れ輪郭を捉えられたが、表面の金属光沢などの空き缶が有する特徴を捉えられなかったため、ペットボトルと誤分類したと考えられる。撮影高度が 60m の場合は相対的に投棄物が小さく写るため（例えば、ペットボトルの地上解像度：35×26pix (30m) → 24×14pix (60m)），誤分類が増えている。また、発泡スチロールは形が長方形で段ボールと類似しているため、撮影時の日射の程度によって誤分類する点が考えられる（図-9(f)）。図-9 には実際に LLaVA で推論した画像と結果の例(a)～(e)を示した。(a)～(c)は正しく分類し、(d)～(f)は誤分類であった。誤分類の要因として、(d)ビニール袋は YOLO で推論した際の Bounding Box が小さく、形状が認識しづらかったため、(e)空き缶は、形が細長くペットボトルに似ているため誤分類した可能性が考えられる。

6. 結論

本研究では UAV 写真を用いた河川投棄物の検出において、生成 AI を用いて手法の高度化を試みた。また本研究では、教師データには Internet 上で一般公開された UAV 撮影画像(UAVVaste)と Stable Diffusion を用いた生成画像(AIGC)の 2 通りを用いた。さらに、投棄物の AI 検出には物体検出モデル YOLO, またその AI 分類にはマルチモーダルモデル LLaVA を組み合わせる方法を検討した。本研究で得られた知見と今後の課題を以下に示す。

(1) AIGCのみの学習時の検出精度が最も高く、69.1%

の再現率が得られたが、AIGCにUAVVasteを組み合わせると精度がやや低下した。これは、図-4、5に関する説明で述べたように、両画像の背景や対象物において相違がありAIGCは対象物、背景及び解像度に多様性があるためと考えられる。

- (2) 推論データでは、背景が自然地形かつ、低高度(高い地上解像度)で撮影すると再現率が高くなり、検討したいずれのCaseも70%以上のスコアとなる。これは、対象物の特徴量及びその輪郭(背景との境界)が明瞭になり、また教師データに含まれる背景が自然地形のためである。
- (3) LLaVAでの分類では段ボールなどの実寸法が比較的大きい投棄物に対しては80%以上の正解率となり、高精度な推論結果が得られた。しかし、小さいペットボトルなどでは推論精度が低く、低い地上解像度の画像ではこの傾向が顕著にみられた。

今後の課題として、(1)生成AI画像での背景を多様化し、YOLOの検出精度を改善すること、(2)LLaVAでは画像中で小さく写る投棄物では分類精度が低下したため、ソフト対応としてPromptの変更や、最新のLMMモデルの利用、また全体を通じてハード対応として、写真解像度の向上を検討する必要がある。また、論文の頁数の制限もあり、LLaVAの分類結果に対する定量的分析は十分ではないため今後の課題としたい。

謝辞：本研究は科学研究費補助金(課題番号：25K07936)及び公益財団法人 河川財団・河川基金(課題番号：2024-5211-067)の助成を受けて実施した。また、国土交通省中国地方整備局 岡山河川事務所より河川情報の提供を受けた。記して謝意を表する。

NOTES

注1) Stable Diffusion, <https://github.com/AUTOMATIC1111/>

stable-diffusionwebui.

注2) Ultralytics:YOLOv5, <https://github.com/ultralytics/yolov5>

注3) LLaVA, <https://github.com/haotian-liu/LLaVA>

注4) UAVVaste, <https://uavvaste.github.io/>

注5) Roboflow, <https://roboflow.com/>

REFERENCES

- 1) Ren, Y., Li Y., and Gao X.: An MRS-YOLO Model for High-Precision Waste Detection and Classification, *Sensors*, 24(13), 4339, 2024.
- 2) 井関禎之, 船田征, 西山 哲 : UAV 写真を用いた不法投棄物の把握, 土木学会論文集, 79 卷 22 号, 2023. [Iseki, S., Funada, M. and Nishiyama, A: Grasping illegal dumping by using UAV photographs, *Journal of Japan Society of Civil Engineers*, Vol. 79, No. 22, 2023.]
- 3) 下江大地, 潘是均, 吉田圭介, 西山哲, 小島 崇 : UAV を活用した河川巡視時のペットボトル検出モデルにおける画像生成 AI の応用, 土木学会論文集 B1 (水工学), 第 81 巻, 16 号, ID: 24-16180, 2025. [Shimoe, D. and Pan, S. and Yoshida K. and Nishiyama, S. and Kojima, T.: Application of image generation ai in model for detecting plastic bottles during river patrol using UAV, *Transaction of the Japan Society of Civil Engineers*, Vol.81, No.16, 2025.]
- 4) 岡野将大, 吉田龍人, 高橋悠太, 藤井純一郎, 天方匡純 : 河川の不法投棄物検知におけるマルチモーダルモデル の適用検証, 2023 年度人工知能学会全国大会 論文集, 2N6-GS-10-04, 2023. [Okano, M. et al.: Validation of the application of a multimodal model in the detection of illegal dumping in rivers, *Proceeding of the Annual Conference the Japanese Society for Artificial Intelligence*, 2N6-GS-10-04, 2023.]
- 5) Pan, S., Yoshida, K., and Kojima, T.: Application of the Prompt Engineering-assisted Generative AI for the Drone based Riparian Waste Detection, *Intelligence, Informatics and Infrastructure*, Vol. 4, No. 2, p.50-59, 2023.

(Received May 30, 2025)

(Accepted September 18, 2025)

STUDY ON AN ENHANCED METHOD FOR RIPARIAN WASTE DETECTION USING DRONE IMAGES AND A LARGE-SCALE MULTIMODAL MODEL

Yusei HANABUSA, Keisuke YOSHIDA, Shijun PAN,
Takashi KOJIMA and Satoshi NISHIYAMA

In recent years, there has been a strong demand for the advancement of river management, leading to active exploration of methods for acquiring river-related information using various platforms such as UAVs and artificial intelligence. In this study, we aimed to detect and classify illegally dumped objects in river environments by utilizing UAV aerial imagery in combination with the object detection model YOLO and the large-scale multimodal model LLaVA. We investigated the impact of different training methods and UAV imaging altitudes on inference performance. As a result, the highest detection accuracy was achieved when the images were captured at low altitude and the training data consisted solely of synthetic images generated using Stable Diffusion's txt2img function. Furthermore, when using LLaVA to classify objects detected by YOLO, high classification accuracy was observed for large objects such as styrofoam. However, the classification accuracy tended to decrease for high-altitude images and smaller objects.

※本書式を用いて最終提出論文，システム上の登録内容が以下の項目を満たしているかを確認してください。確認したものは，□を☑に変更してください。そのうえで，責任著者名を記入し PDF ファイルに変換したものを，最終論文とともに EM 上にて提出してください。

土木学会論文集特集号（水工学）EM チェックリスト 2025

- ☑ 論文は土木学会論文集の書式に則り執筆し，ページ数は和文 7 頁以内，英文 6 頁以内である。和文論文では，和文の REFERENCES に対して英語が併記されている。
- ☑ 論文 PDF の最終ページに(Received May 30, 2025) (Accepted September 18, 2025)が記載されている。
- ☑ 論文 PDF 中のページ番号を削除済みである。(Accept (書式修正のみ/最終原稿提出) のときのみ)
- ☑ 論文 PDF 中の英語タイトルはすべて大文字，英語著者名は名が頭文字のみ大文字，姓がすべて大文字で記載されている。
- ☑ 論文 PDF 中のキーワードはイタリック，英語で記載されている。
- ☑ 論文 PDF のレイアウトやフォントが規定通りに作成されている（マージン，フォントサイズなど）。
- ☑ Editorial Manager 上に登録した論文タイトル【日本語・英語】が論文 PDF と完全一致している（大文字・小文字・イタリックなどの書式設定も含む）。
- ☑ Editorial Manager 上に登録した著者情報【著者名，所属，掲載順序】が論文 PDF と完全一致している（大文字・小文字・姓名表示順も含む）。
- ☑ Editorial Manager 上に登録した Corresponding Author が論文 PDF と一致している。また論文 PDF 中に Corresponding Author が明記されている。ただし，単著の場合，論文上に Corresponding Author の記述は不要です。
- ☑ PDF ファイルは，土木学会論文集の PDF 作成手引きに則り作成し，ファイル容量は 10MB 以内である。
<https://committees.jsce.or.jp/jjsce/ptebiki>

最終提出前に上記条件を満たしたことを確認し，提出いたします。

責任著者名 英 佑成

注意：所属・役職に関しては論文に記載の内容が J-Stage 論文および講演会プログラムに表示されますので，誤りのないようにご注意ください。